

2025 B.D.A x 동서발전 x 60Hz

풍력 발전량 예측 공모전



Contents



01.
공모전 개요

02.
EDA

03.
데이터 전처리

04.
모델링

05.
참고문헌

1. 공모전 주제

기상/환경 데이터를 활용한 하루 전 풍력 발전량 예측

2. 제공 데이터

- LDAPS 데이터
- Target(yield_kwh) 데이터
- SCADA 데이터 및 발전단지 데이터

3. 공모전 규칙

- 예측 대상일 전날(한국시 15시 이전)까지 생성된 NWP 데이터만 사용 가능
- 학습에 추론 대상 기간의 기상 실측 데이터 및 재분석 예측 데이터 사용 불가능
- SCADA 데이터는 학습에는 사용 가능하지만, 추론 단계에서는 사용 불가능

4. 학습 및 예측 기간


- 영덕
학습데이터: 2024.4 ~ 2025.3 홀수달
예측 기간: 2024.4 ~ 2025.3 짝수달
- 양양
학습데이터 : 2024.4 ~ 2025.3 짝수달
예측 기간 : 2024.4 ~ 2025.3 홀수달
- 경주2풍력
학습데이터 : 2020 ~ 2023 4년치.
예측 기간 : 2024년 1년

풍력 발전량은 풍속·풍향·기온에 의해 직접적으로 결정되므로,
37가지 물리 변수(**속도·방향·온도**)에 집중한 EDA 및 파생 변수 생성을 진행



풍속 관련 피처

uws_10m, vws_10m, usm_5m,
vsm_5m, mgws_0m, fvmax_50m,
fvmin_50m



풍향 관련 피처




uws_10m, vws_10m, usm_5m,
vsm_5m



기온 관련 피처

ta, ta_1p5m, tdp_1p5m, sh_1p5m,
rh_1p5m, p

✓ 풍속이 클수록 발전량이 많을 것이다




- 풍속이 크다고 무조건 에너지량이 많아지지 않음
- 풍속이 약 25m/s 이상인 구간부터는 더 이상 에너지가 생산되지 않음



풍속이 발전량에 비선형적으로 영향을 미치는 특성을 반영하기 위해 풍속 제곱·세제곱항 파생변수 생성
효율구간 상한을 적용한 파생변수 생성

✓ 풍속은 특정 구간에서 주로 발생할 것이다




- 데이터의 대부분이 3~10m/s 구간에 집중
- 터빈이 실제 운전되는 구간의 대부분은 저·중속 풍속 영역임을 의미
- 로그정규분포(log-normal) 혹은 Weibull 분포 형태와 유사함



풍속을 15m/s 이하로 clip 처리하여 모델이 주요 구간에 집중
Cut-in, Rated 구간을 반영한 Power Curve 파생변수를 추가

*EDA에서 그려진 그래프는경주 풍력의 LDAPS 그래프로 양양/영덕도 비슷한 양상

✓ 난류가 낮을수록 에너지 생산량이 높을 것이다



- 난류가 높을수록 발전량의 중앙값이 감소하고 분산이 증가하는 경향
- 난류가 낮을수록 안정적이고 효율적인 발전이 이루어진다는 가설이 데이터로 확인




난류는 풍속의 불규칙성을 나타내는 지표로,
터빈 효율 저하를 설명하기 위한 파생변수로 생성

*난류: 바람의 최대 속도와 최소 속도 차이를 바람의 평균 속도로 나눈 값


$$\text{Turbulence Intensity (TI)} = \frac{fv_{max_50m} - fv_{min_50m}}{\frac{fv_{max_50m} + fv_{min_50m}}{2}}$$

✓ 특정 풍향에서 발전량이 집중될 것이다


Mean Power Generation by Wind Direction_gyeongju



Mean Power Generation by Wind Direction_yangyang



Mean Power Generation by Wind Direction_yeongduck





- 지역별로 바람의 우세 방향이 다르며, 이는 터빈 설치 각도 및 풍향 보정 피처가 모델 성능에 중요한 영향을 줄 수 있음



풍속과 풍향의 상호작용을 통한 파생변수 생성
sin/cos 변환을 통해 주기성을 보존하고 모델이 방향성을 부드럽게 학습

✓ 기온이 낮을수록(공기 밀도가 높을수록) 풍력 발전량이 높을 것이다



- 온도가 높을수록 발전량이 감소하는 뚜렷한 음의 상관관계 확인
- 공기 밀도가 증가할수록 발전량이 비례적으로 증가하는 경향



기온이 낮고 공기 밀도가 높을수록 풍력 발전량이 증가하는 경향을 보여,
물리식 기반의 파생변수 `air_density` 생성의 타당성을 검증

✓ 고상관 변수 선별

발전량과 상관계수 절댓값이 높은
상위 5~15개 원본 변수를 선택

✓ 다중 시차 생성

각 변수에 대해 1시간, 3시간, 6시간, 12시간,
24시간 시간 피처(Lag Feature) 생성

✓ 시간적 의존성 포착

과거의 기상 조건이 현재 발전량에 미치는
영향을 명시적으로 반영




**발전량에 영향을 미치는 주요 기상 요인을 선별하고,
과거 시점의 기상 상태가 현재 발전량에 미치는 시차 효과를 반영**

✓ 불필요한 컬럼 제거

- elev, lsmask, sfr, latitude, longitude 컬럼은 데이터셋 전체에 걸쳐 값이 변하지 않는 상수로 모든 행에서 동일한 정보를 제공
→ **5개의 컬럼 제거 진행**

컬럼명	고유값 수
elev	1
lsmask	1
sfr	1
latitude	1
longitude	1

✓ 기상 데이터 특성을 고려한 이상치 보정



- 비율 타입: 0~1 범위로 제한 (hcc, mcc, lcc, sfa_1p5m)
- 강수·적설량: 음수 값 → 0으로 보정 (물리적으로 불가능)
- 상대습도: 0~100% 범위로 제한 (rh_1p5m)

✓ 다중 앙상블 전략

전체



Seed [42, 510, 1007, 1101, 2024]
여러 개의 Seed를 앙상블 (평균)

시간대별



새벽: 00~05시, 아침: 06~11시
오후: 12~17시, 저녁: 18~23시

+ 5개 Seed의 평균

발전량별



저발전: 0~Q1, 중발전: Q1~Q3,
고발전: Q3~max

+ 5개 Seed의 평균

같은 시간대 또는 발전량 범주에 속하는 데이터만 사용해
해당 범주의 발전량을 정교하게 예측하도록 모델을 세분화

✓ 다양한 조합 시도

1.전체, 2.시간대별, 3.발전량별

4.전체+시간대별, 5.전체+발전량별, 6.시간대별+발전량별

7.전체+시간대별+발전량별, 8. 전체 + K-Fold + 시간대별, **총 8가지**

경주

전체 + K-Fold + 시간대별 앙상블이 최적

양양

전체 + 시간대별 + 발전량별 앙상블이 최적

영덕

전체 + 시간대별 + 발전량별 앙상블이 최적


**단일 모델로는 시간대·발전 수준별 편차를 충분히 설명하기 어렵기 때문에
다양한 조합을 실험하여 최적의 세분화 수준을 탐색함**

✓ 경주

LGBM

전체


5개 Seed 앙상블



예측값

K-Fold


5 K-Fold



예측값

시간대별

새벽/아침/오후/저녁



예측값

1) 3개의 예측 결과를 단순 평균, 2) 성능 기반 가중(0.3, 0.3, 0.4), 3) 시간대별 동적 가중


LightGBM 기반의 시간대별 동적 가중 앙상블을 통해
시계열 특성과 시간대별 패턴을 정밀 반영하여 예측 오차를 최소화

* <시간대별 동적 가중 앙상블>
시간대별로 가장 예측 성능이 좋은 모델에
더 높은 가중치를 주어 예측을 조합하는 방식

✓ 양양
XGBoost

전체


5개 Seed 앙상블



예측값

시간대별


새벽/아침/오후/저녁



예측값

발전량별

저발전/중발전/고발전



예측값

1) 3개의 예측 결과를 단순 평균, 2) 성능 기반 가중(0.3, 0.4, 0.3), 3) 시간대별 동적 가중


XGBoost 기반의 시간대별 동적 가중 앙상블을 통해
시계열 특성과 시간대별 패턴을 정밀 반영하여 예측 오차를 최소화

✓ 영덕

LGBM

전체


5개 Seed 앙상블



예측값

시간대별


새벽/아침/오후/저녁



예측값

발전량별

저발전/중발전/고발전



예측값

1) 3개의 예측 결과를 단순 평균, 2) 성능 기반 가중(0.3, 0.3, 0.4), 3) 시간대별 동적 가중

LightGBM 기반의 시간대별 동적 가중 앙상블을 통해
시계열 특성과 시간대별 패턴을 정밀 반영하여 예측 오차를 최소화

하이퍼파라미터 튜닝

RandomizedSearchCV + K-Fold Validation

RandomizedSearchCV

하이퍼파라미터의 특정 범위 내에서 무작위로
선택하여 모델을 평가하고, 이 중에서 가장
좋은 성능을 보이는 파라미터를 탐색

K-Fold Validation

K개의 데이터 폴드 세트를 만들어서 K번만큼
각 Fold set에 학습과 검증 평가를 반복적으로
수행



과적합 방지 및 성능 소폭 향상

〈최종 제출 결과〉

최종 점수: 304.57, NMAE: 19.15%, 정산금 획득률: 20.67%



<seed ensemble 앙상블 참조>

<https://dacon.io/competitions/official/236531/codeshare/12783?page=1&dtype=recent>

<CNN-LSTM 논문>

<https://www.journalsnre.com/xml/33076/33076.pdf>

<특성공학 참조>

<https://dacon.io/competitions/official/236066/codeshare/7720?page=1&dtype=recent>

Q&A
감사합니다